Bayes und EMA

Workshop DGPs Gesundheitspsychologie 2025

EATING BEHAVIOR LABORATORY SALZBURG
PARIS LODRON UNIVERSITÄT SALZBURG

Vorstellung

- Zu mir:
  - Post-Doc Universität Salzburg
  - Hintergrund: Kognitionswissenschaften, Neuropsychologie, Gesundheitspsychologie
  - Bayesianische Statistik mit brms, STAN für RCTs, EMA Beobachtungsstudien, Meta-Analysen,…
  - Website: https://christophbg.github.io/
- 4/13 haben Erfahrung mit Bayes
- Erwartung: Grundlagen, Anwendung, Überblick

Workshop Plan

- Einführung
- Grundlagen
  - Wahrscheinlichkeit
  - Bayes Formel
    - Prior
    - Likelihood
    - Posterior
  - Sampling
- Workflow
- Anwendung an Beispielen
  - Simple Regression
  - MLM und mehr
- Übung in R

Einführung

Logik, Mathematik

Bayes

Spezifische Fragestellungen
- „Null Ergebnisse“
- Effektgrößen ermitteln (nicht NHST)

Probleme mit
frequentist Modellen

?

EATING BEHAVIOR LABORATORY SALZBURG

PARIS LODRON UNIVERSITÄT SALZBURG

Vorteil Bayes für Null Ergebnisse – Meta-Analyse Beispiel

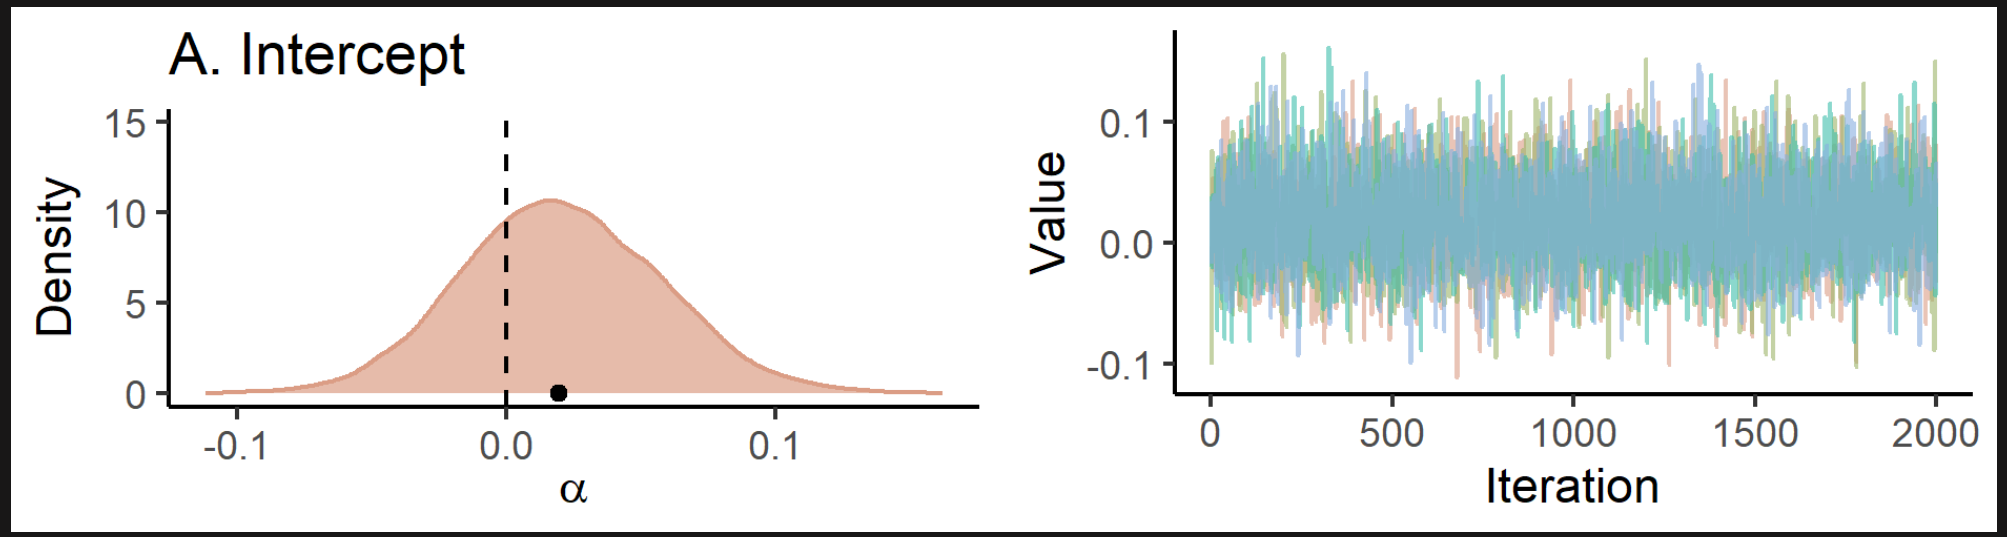

Bamberg, C., & Moreau, D. (2025). A Systematic Review and Meta-Analysis of the Acute Effect of Fasting on Cognitive Performance. *Accepted at Psych. Bull.*

Vorteile Bayes für EMA

- Eignet sich gut, um interessante Fragen zu beantworten:
  - Wie groß ist der Zusammenhang zwischen X & Y?
  - Welchen Wert für Y sollte ich erwarten wenn X =?
  - *Nicht:* ist es nicht der Fall, dass es keinen Effekt gibt?
- Keine Mindest-Stichprobe (im Prinzip)
  - EMA oft mit kleinem N
- Drückt Unsicherheit im Modell durch Wahrscheinlichkeitsverteilung aus
  - EMA Daten haben viel Varianz, Bayes macht diese quantifizierbar
- Vorwissen kann einbezogen werden, Iteration möglich
  - EMA = mobil & übersetzbar -> gut für Iteration

Grundlagen

- Wahrscheinlichkeit
  - Frequentist: long-term frequencies
  - Bayes:
    - Relative Plausibilität (McElreath)
      - ~ Die Wege zählen, wie ein Ereignis zustande kommen kann, relativ zu allen Möglichkeiten
    - Unsicherheit
- Alle Parameter werden geschätzt, haben eine Verteilung

Übung

- Welche Fragestellung interessiert dich?
- Z.B. „wie hängt Stimmung mit physischer Aktivität zusammen?“
- *Überlegt für 3 Minuten*

Bayes Formula

$$P(H|D) = \frac{P(H) * P(D|H)}{P(D)}$$

EATING BEHAVIOR LABORATORY SALZBURG

PARIS LODRON UNIVERSITÄT SALZBURG

Bayes Formula

Posterior

$$P(H|D)$$

Bayes Formula

Prior *Likelihood*

Posterior

$$P(H|D) = \frac{P(H) * P(D|H)}{}$$

EATING BEHAVIOR LABORATORY SALZBURG

PARIS LODRON UNIVERSITÄT SALZBURG

Bayes Formula

Prior *Likelihood*

Posterior

$$P(H|D) = \frac{P(H) * P(D|H)}{P(D)}$$

Marginal Likelihood (normalising constant)

Bayes Formula

$$P(H|D) = \frac{P(H) * P(D|H)}{P(D)}$$

Posterior *Prior* *Likelihood*

$$P(H|D) \propto P(H) * P(D|H)$$

Die relative Plausibilität eines Ereignisses, gegeben den Daten,
ist proportional zur
angenommenen Plausibilität des Ereignisses
multipliziert mit
der Wahrscheinlichkeit der Daten gegeben des Ereignisses.

EATING BEHAVIOR LABORATORY SALZBURG
PARIS LODRON UNIVERSITÄT SALZBURG

Prior $P(H)$

- Annahmen a priori (vor der Erfahrung)
- Meist geringer Effekt auf Posterior, bei großen Datenmengen
- Welche Werte kann ich beobachten?
  - Körpergröße
  - EMA Slider Fragen
- brms Default Prior:
  - „flat“ für Prädiktoren
  - Student-T für Intercept, half Student-T für SD

Übung zu Prior $P(H)$

- Überlege dir welche Vorannahmen du treffen kannst:
- Prior für AV (Intercept)
  - Welche Werte sind möglich für die AV?
  - Was ist der zu Grunde liegende Prozess -> welche Verteilung kannst du annehmen für die AV?
- Wie groß ist der zu erwartende Zusammenhang zwischen UV und AV?
- *Überlegt für 3 Minuten und tauscht euch kurz untereinander aus*

Likelihood $P(D/H)$

- Welche Verteilung der Ergebnisvariable (Outcome) nehmen wir an?

Lineares Model für Likelihood $P(D|H)$

- Wir wollen die Ergebnisvariable durch Prädiktoren beschreiben, für Regression nehmen wir eine lineare Gleichung.
- Bei Normalverteilung schätzen wir den Mittelwert:

$$Y_i \sim Normal(\mu_i, \sigma)$$
$$\boldsymbol{\mu_i = \alpha + \beta * x_i}$$

- Wir brauchen einen passenden Link zwischen Daten und Modell
- Normal: Identity-Link, Bernoulli: Logit-Link, Beta: Logit-& Log-Link,…

Posterior $P(H|D)$

$$P(H|D) \propto P(H) * P(D|H)$$

EATING BEHAVIOR LABORATORY SALZBURG

PARIS LODRON UNIVERSITÄT SALZBURG

Übung Posterior $P(H|D)$

- (Welche Verteilung erwartest du?)
- Was für Parameter musst/kannst du schätzen für diese Verteilung?
- Welche Verbindung zwischen Daten und Modell ist möglich und sinnvoll?
- *Überlegt für 3 Minuten*

Bayes Formula

Prior *Likelihood*

Posterior

$$P(H|D) = \frac{P(H) * P(D|H)}{P(D)}$$

Marginal Likelihood (normalising constant)

EATING BEHAVIOR LABORATORY SALZBURG

PARIS LODRON UNIVERSITÄT SALZBURG

Sampling

- Analytische Methoden scheitern schnell => probabilistic sampling
- MCMC Interactive Gallery
  - Von Chi Feng https://github.com/chi-feng/mcmc-demo

- Pragmatisch:
  - Iterations >= 2000, warm-up = ½ iterations
  - 4 chains, Parallelisierung nutzen, falls möglich
  - Seed für Reproduzierbarkeit
- Tipp: Sampling an workflow anpassen

Workflow

I. Kausales Modell

II. Generative Simulation

III. Statistisches Modell an Simulation testen

IV. Statistisches Modell updaten (Prior anpassen, etc.)

V. Daten erheben

→ DAG and Bayes for EMA - SAA 2025

1. Exploration
   1. Was ist der Daten-generierende Prozess?
   2. Wie sind die Daten verteilt?
2. Prior wählen
   1. Prior predictive simulation
3. Regressionsmodell aufstellen (Fokus auf brms)
   1. Compilation testen
   2. Sampling
4. Diagnostik
   1. R-hats, Effective sample sizes
   2. Trace-plots
5. Posterior prediction
   1. Summary interpretieren
   2. Posterior density plotten
   3. Posterior prediction

Workflow

1. Exploration
   1. Was ist der Daten-generierende Prozess?
   2. Wie sind die Daten verteilt?
2. Prior wählen
   1. Prior predictive simulation
3. Regressionsmodell aufstellen (Fokus auf brms)
   1. Compilation testen
   2. Sampling
4. Diagnostik
   1. R-hats, Effective sample sizes
   2. Trace-plots
5. Posterior prediction
   1. Summary interpretieren
   2. Posterior density plotten
   3. Posterior prediction

Dateien für Übung

- Ladet die Daten und Skripte hier herunter:
  - https://github.com/ChristophBg/workshop
  - DGPS_WS_simulate_EMA_data.R
  - (simulated_EMA_data.csv)
  - DGPS_WS_analysis.Rmd

Beispieldaten

- Ecological Momentary Assessment
- N = 20, 6 prompts/ Tag, 14 Tage
- Antwort-Rate ~ 80%
- Positive & negative Stimmung, physische Aktivität: Slider-Fragen 0—100; in Gesellschaft: Ja/Nein
- Fragestellung:
  - Was ist der Zusammenhang zwischen negativer Stimmung und physischer Aktivität?
    - Kontrolliert für Gesellschaft

1. Exploration

- Daten-generierender Prozess?

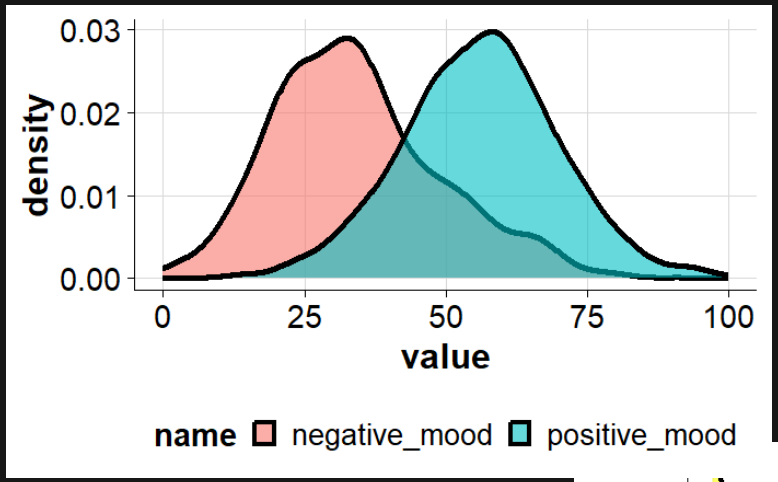

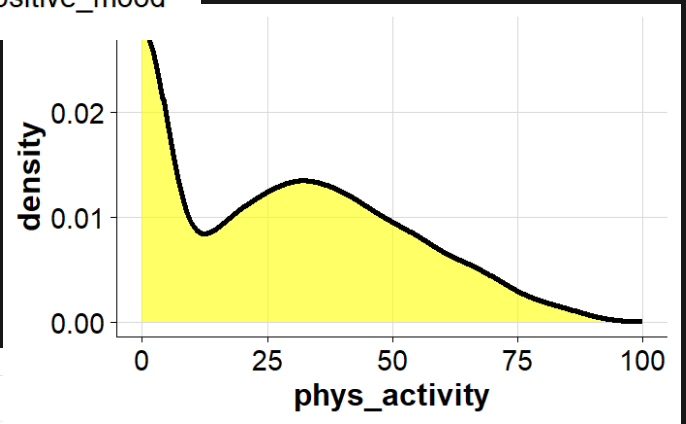

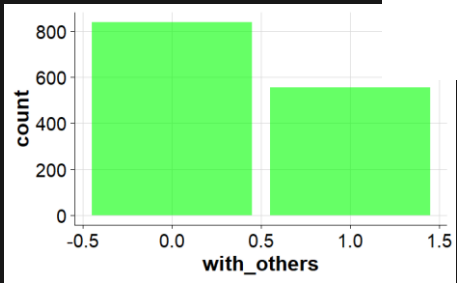

2. Prior

get_prior(negative_mood ~ phys_activity, data=d)

```
                   prior     class          coef group resp dpar nlpar lb ub       source
                  (flat)         b                                                 default
                  (flat)         b phys_activity                              (vectorized)
student_t(3, 32.6, 14) Intercept                                                 default
   student_t(3, 0, 14)     sigma                                       0         default
```

→ Prior für Intercept, Sigma, Prädiktor

2. Prior

- Intercept:
  - Uniform(0, 100)
  - Normal(50, 25)
  - Normal(33, 15)
- Sigma:
  - Half-Cauchy, Truncated Student (default), Exponential, …
- Prädiktor:
  - Normal(0, 10)
  - Normal(5, 5)

→ Mixed Effects Location Scale Model of Craving

2. Prior

```
get_prior(
        negative_mood ~ phys_activity + with_others + (1 + phys_activity + with_others|id/day),
data=d)
```

prior	class	coef	group	resp	dpar	nlpar	lb	ub	source
(flat)	b								default
(flat)	b	phys_activity							(vectorized)
(flat)	b	with_others							(vectorized)
lkj(1)	cor								default
lkj(1)	cor		id						(vectorized)
lkj(1)	cor		id:day						(vectorized)
student_t(3, 32.6, 14)	Intercept								default
student_t(3, 0, 14)	sd						0		default
student_t(3, 0, 14)	sd		id				0		(vectorized)
student_t(3, 0, 14)	sd	Intercept	id				0		(vectorized)
student_t(3, 0, 14)	sd	phys_activity	id				0		(vectorized)
student_t(3, 0, 14)	sd	with_others	id				0		(vectorized)
student_t(3, 0, 14)	sd		id:day				0		(vectorized)
student_t(3, 0, 14)	sd	Intercept	id:day				0		(vectorized)
student_t(3, 0, 14)	sd	phys_activity	id:day				0		(vectorized)
student_t(3, 0, 14)	sd	with_others	id:day				0		(vectorized)
student_t(3, 0, 14)	sigma						0		default

2. Prior

Half-Cauchy Verteilung für SD

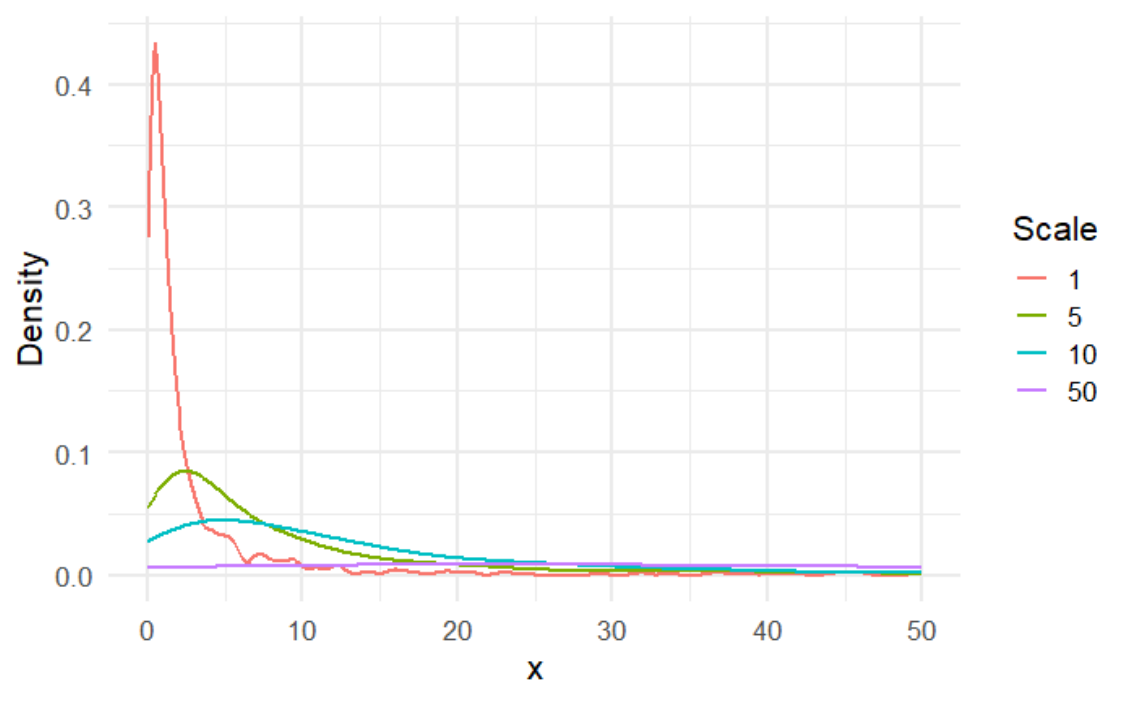

2. Prior

```
prior_bm1 = c(prior(normal(50, 10), class = "Intercept"),
              prior(normal(0, 5),  class = "b"),
              prior(cauchy(0,5), class = "sigma"))
bm1_prior <- brm(
  negative_mood ~ phys_activity,
  data = d,
  family = gaussian(),
  prior = prior_bm1,
  sample_prior = "only",   # only sampling from prior
  iter = 2000, chains = 4, seed = 123)
```

2. Prior

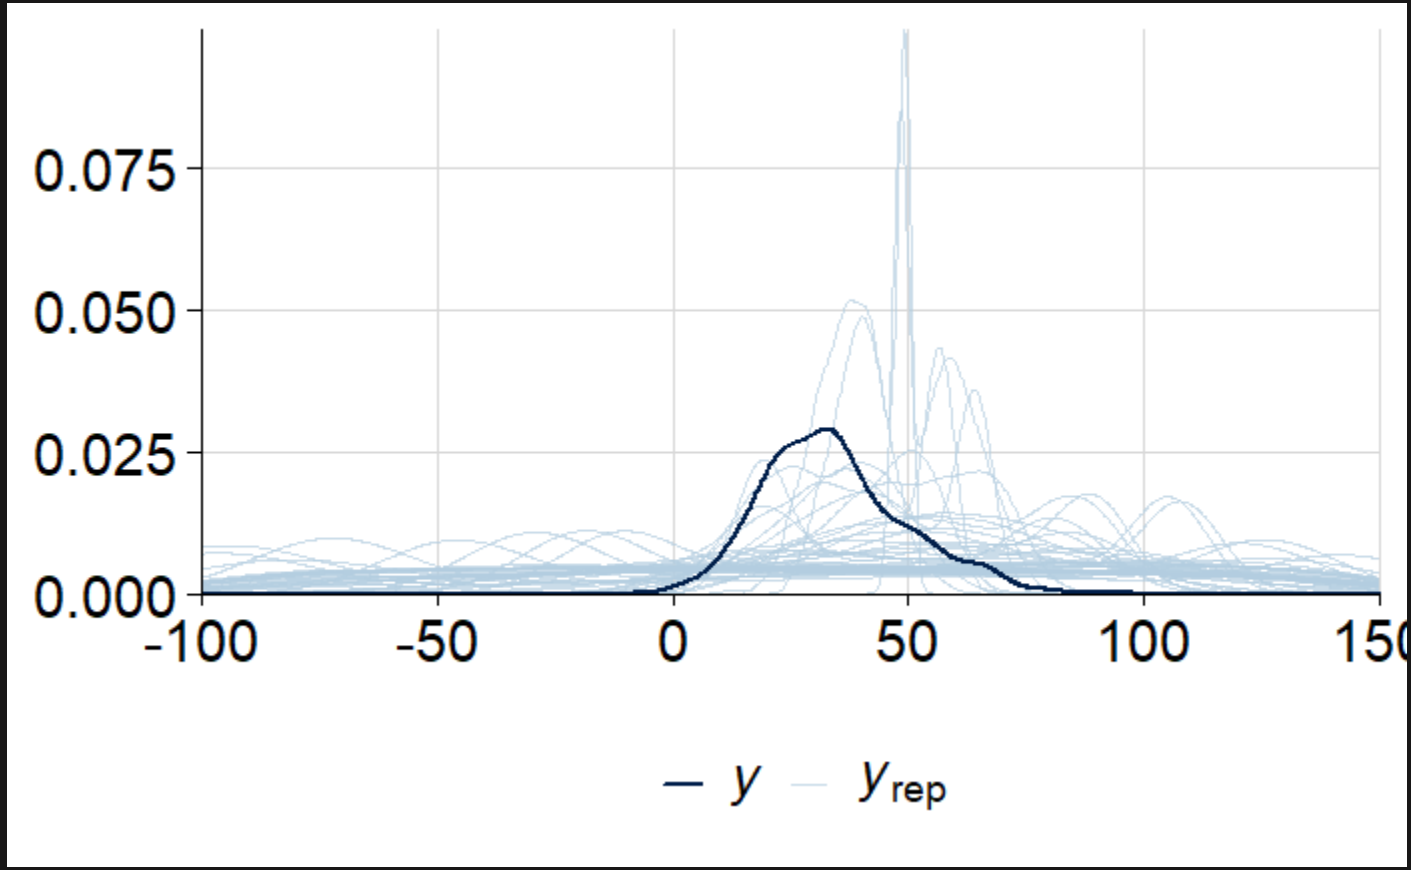

2. Prior

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        49.14    127.02  -201.17   300.96 1.00     3529     3110
phys_activity     0.04      4.94    -9.40    10.01 1.00     3527     2834

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    23.64    173.61     0.17   119.68 1.00     3451     2146

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

3. Regressionsmodell aufstellen

- brm(formula=„negative_mood ~ phys_activity“, data=d, prior=…)
- Compilation testen
  - Brms → R STAN → C++
  - Tipp: *brm(…,chains = 1, iter = 2…)*
  - Output wie erwartet? → Sampling
- Sampling
  - Output:
    - …
    - Chain 1: Iteration: 1000 / 2000 [50%] (Warmup)
    - Chain 1: Iteration: 1001 / 2000 [50%] (Sampling)
    - …
  - Tipp: *brm(…file=„abc“,file_refit=„on_change“…)*

4. Diagnostik

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    33.86    36.18 1.00     3906     3133
phys_activity    -0.03      0.02    -0.07    -0.00 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.34    15.42 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

4. Diagnostik

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    33.86    36.18 1.00     3906     3133
phys_activity    -0.03      0.02    -0.07    -0.00 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.34    15.42 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

4. Diagnostik

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    33.86    36.18 1.00     3906     3133
phys_activity    -0.03      0.02    -0.07    -0.00 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.34    15.42 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

4. Diagnostik

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    33.86    36.18 1.00     3906     3133
phys_activity    -0.03      0.02    -0.07    -0.00 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.34    15.42 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

4. Diagnostik

plot(bm1)

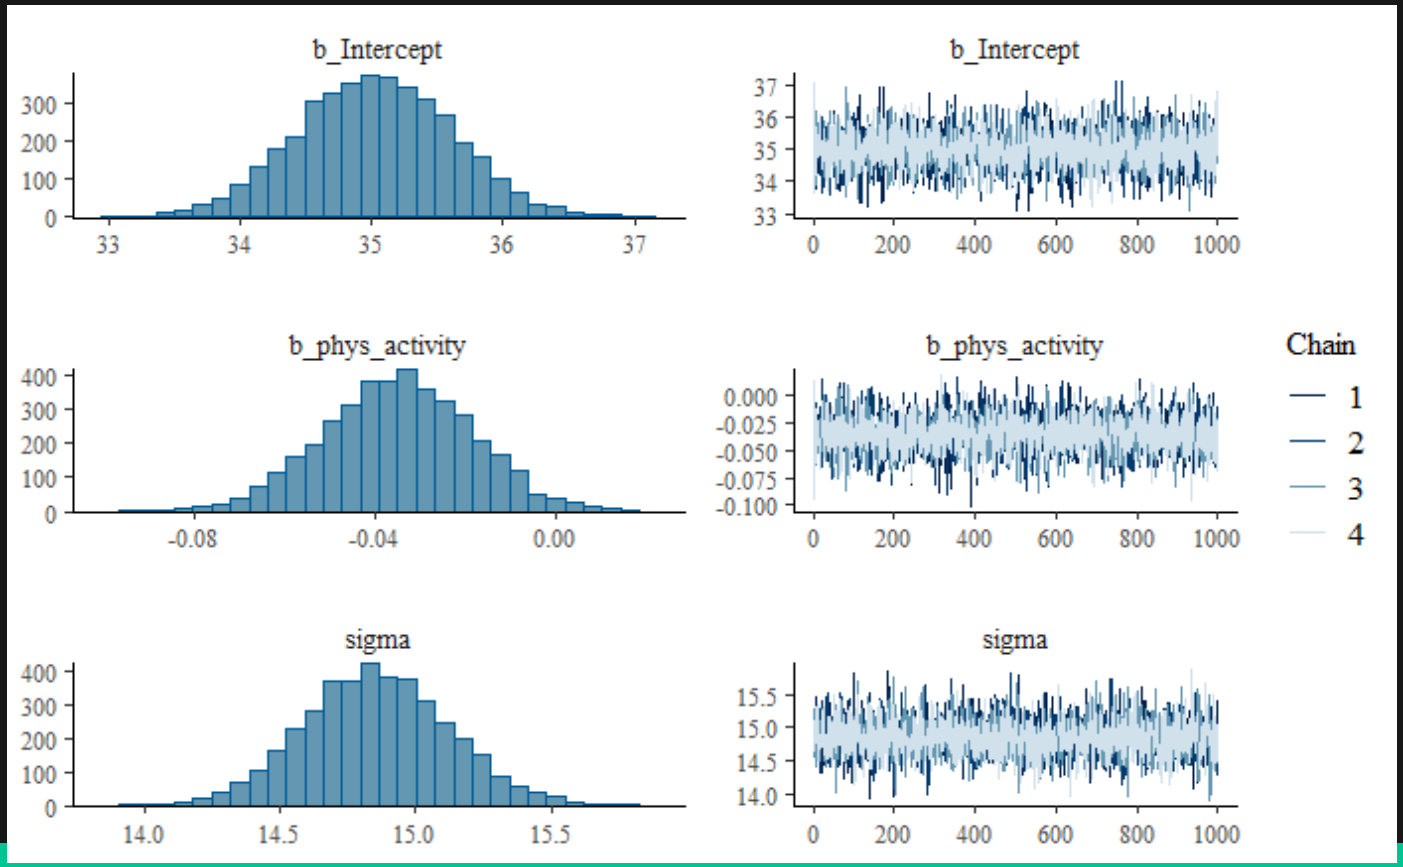

5. Posterior

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    33.86    36.18 1.00     3906     3133
phys_activity    -0.03      0.02    -0.07    -0.00 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-95% CI u-95% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.34    15.42 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

5. Posterior

```
 Family: gaussian
  Links: mu = identity; sigma = identity
Formula: negative_mood ~ phys_activity
   Data: d (Number of observations: 1397)
  Draws: 4 chains, each with iter = 2000; warmup = 1000; thin = 1;
         total post-warmup draws = 4000

Regression Coefficients:
              Estimate Est.Error l-90% CI u-90% CI Rhat Bulk_ESS Tail_ESS
Intercept        35.02      0.60    34.05    35.99 1.00     3906     3133
phys_activity    -0.03      0.02    -0.06    -0.01 1.00     3960     2868

Further Distributional Parameters:
      Estimate Est.Error l-90% CI u-90% CI Rhat Bulk_ESS Tail_ESS
sigma    14.86      0.28    14.42    15.31 1.00     3760     2843

Draws were sampled using sampling(NUTS). For each parameter, Bulk_ESS
and Tail_ESS are effective sample size measures, and Rhat is the potential
scale reduction factor on split chains (at convergence, Rhat = 1).
```

5. Posterior

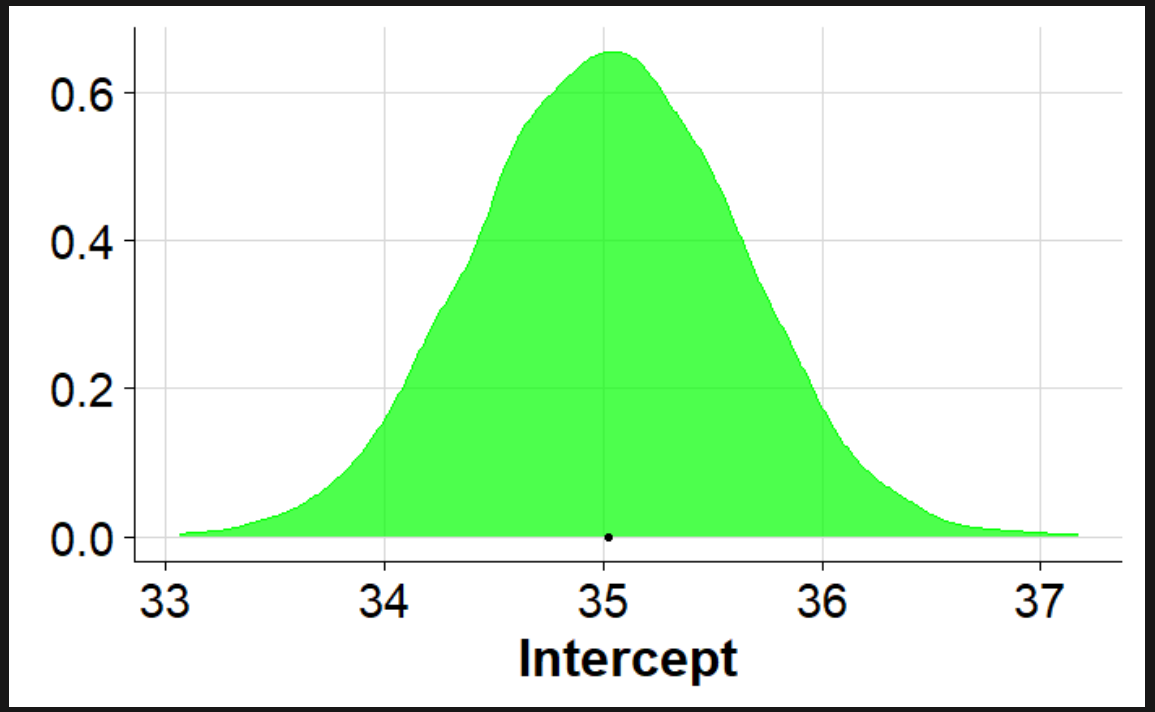
0.6
0.4
0.2
0.0
33
34
35
36
37
Intercept

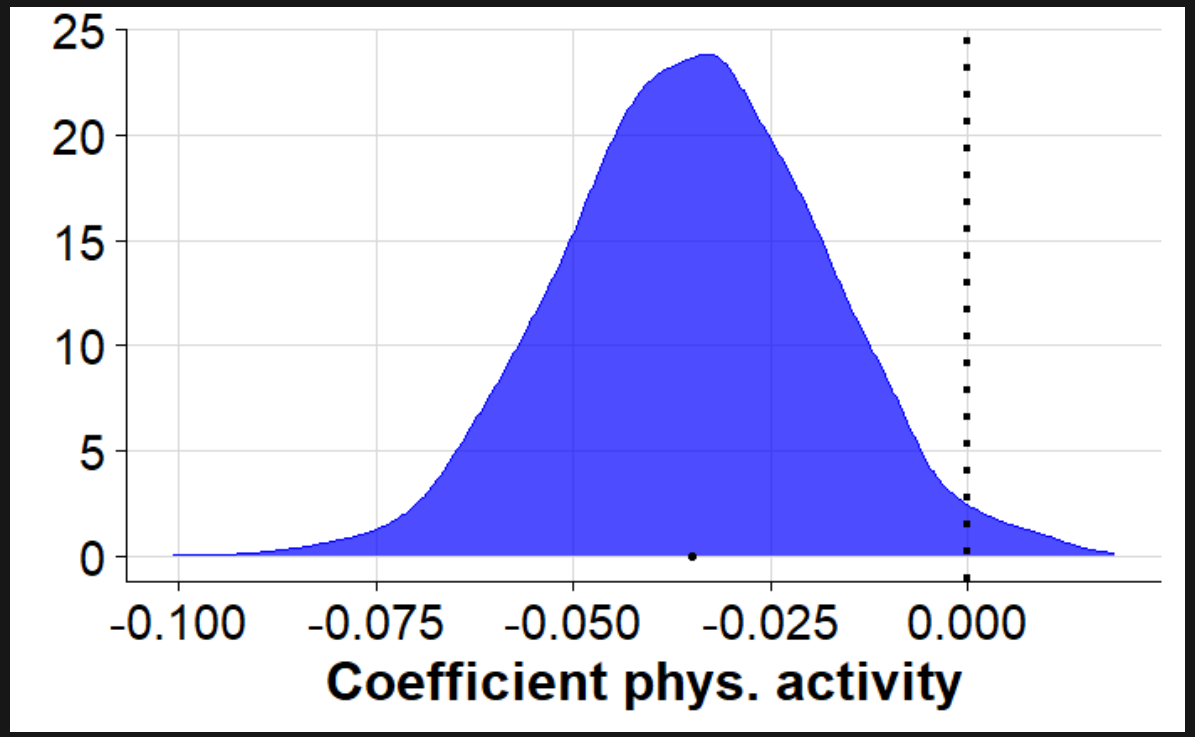
25
20
15
10
5
0
-0.100
-0.075
-0.050
-0.025
0.000
Coefficient phys. activity

5. Posterior

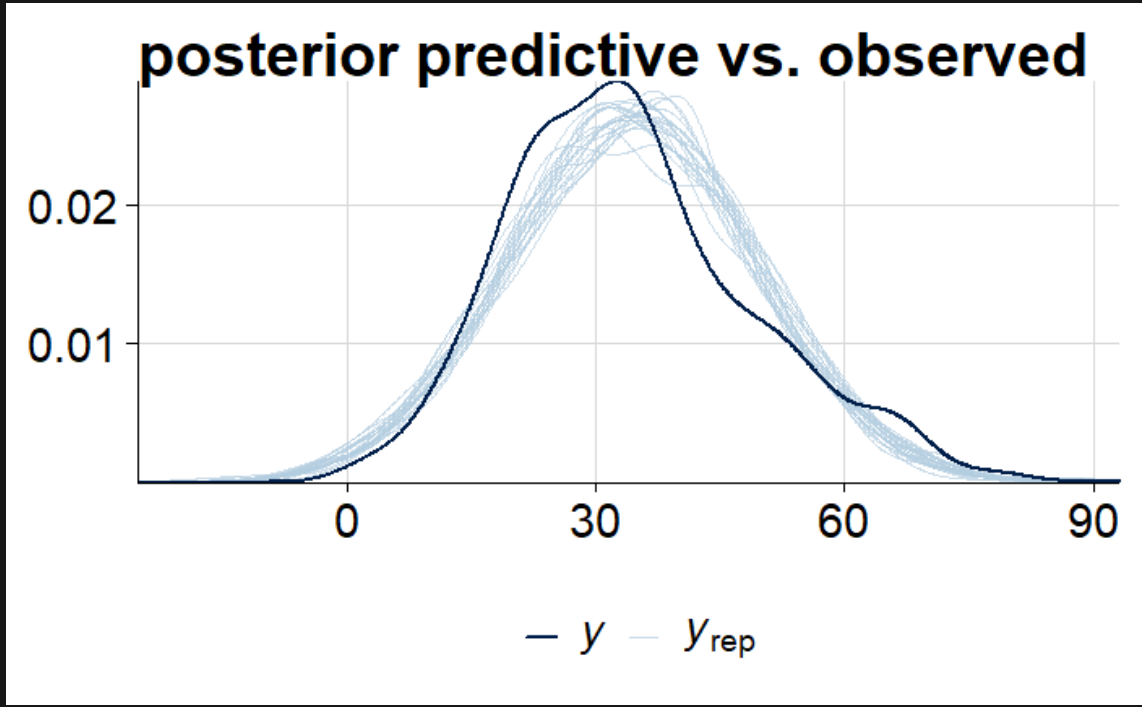

Beispiel 2 – live demo

- Multi-level Model
- (zero-inflated beta-Model)

Übung

- Siehe DGPS_WS_analysis.Rmd

Bayes und EMA

Workshop DGPs Gesundheitspsychologie 2025

Fragen an: christoph.bamberg@plus.ac.at

EATING BEHAVIOR LABORATORY SALZBURG
PARIS LODRON UNIVERSITÄT SALZBURG